Desenvolvimento e Avaliação Comparativa de Assistente Virtual Acadêmico

RAG Clássico vs. Agentic RAG via Model Context Protocol (MCP)

Apresentação Parcial do Trabalho de Conclusão de Curso (TCC II)
Discente: Daniel G. D. Silva | **Orientador:** Prof. Me. Ederson N. F. G. Júnior
Instituição: Instituto Federal de Minas Gerais (IFMG) — Campus Ouro Branco
Curso: Bacharelado em Sistemas de Informação | **Outubro de 2026**

Slide 1 — Introdução: Contextualização e Escopo

Contextualização e Motivação

- **Labirinto Normativo:** Diretrizes acadêmicas dispersas em múltiplos PDFs extensos (PPCs, regulamentos de TCC, estágio, ementas e calendários);
- **Esforço Cognitivo:** Alunos enfrentam barreiras para localizar regras operacionais de trancamento, pré-requisitos e atividades complementares;
- **Sobrecarga Administrativa:** Demandas repetitivas sobrecarregam secretarias e coordenações de curso.

Escopo da Solução

Dimensão	O que o projeto faz	O que o projeto não faz
Fontes de dados	FAZ Responde a dúvidas com base em documentos oficiais do campus (PPC, ementário e regulamentos).	NÃO FAZ Não acessa notas, histórico ou dados pessoais do aluno (SUAP).
Operação	FAZ Somente consulta e leitura, comparando **RAG Clássico** e **RAG Agêntico (MCP)**.	NÃO FAZ Não altera cadastros nem executa solicitações, como trancamento de matrícula.
Infraestrutura	FAZ Roda 100% em hardware local, com modelos de código aberto.	NÃO FAZ Não usa APIs pagas em nuvem, evitando custos e exposição de dados.

Slide 2 — Problema e Objetivos da Pesquisa

Descrição e Relevância do Problema

Modelos de linguagem generativos (LLMs) produzem respostas probabilísticas sujeitas a **alucinações factuais**, inventando prazos e normas inexistentes. Por outro lado, soluções baseadas em nuvem comercial geram custos em escala e fragilidade à privacidade. É imperativo investigar arquiteturas locais que garantam **ancoramento factual rigoroso**.

Pergunta da Pesquisa

"Como viabilizar um assistente virtual acadêmico 100% local e soberano, e quais são os trade-offs dessa abordagem em latência, governança e assertividade entre RAG Clássico e RAG Agêntico via MCP, utilizando modelos compactos em hardware modesto?"

Objetivos do Trabalho

Objetivo Geral: Projetar, implementar e avaliar comparativamente um assistente virtual acadêmico para o IFMG Campus Ouro Branco operando em infraestrutura local.

Objetivos Específicos:

1. Estruturar pipeline de ingestão adaptativa com *chunking* semântico orientado ao domínio normativo;
2. Implementar busca híbrida (BGE-M3 + FTS com RRF ponderado) e servidor MCP via *stdio* restrito;
3. Desenvolver controle leve de concorrência em GPU (semáforo de VRAM) para execução estável;
4. Mensurar latências de pipeline e realizar testes preliminares de campo com discentes.

Slide 3 — Trabalhos Relacionados e Diferencial da Proposta

Trabalho / Autor	Abordagem Tecnológica	Limitações Identificadas	Diferencial da Nossa Proposta
Helena / UFOP (Monteiro, 2021)	PLN Tradicional via IBM Watson Assistant	Mapeamento manual de intenções; fluxos rígidos que quebram com mudanças em resoluções	**Extração Dinâmica via RAG:** Atualização imediata com ingestão de novos regulamentos em PDF
PROGRAD / UFOP (Barbosa, 2023)	RAG com LlamaIndex + ChatGPT (OpenAI)	Custo recorrente por token em nuvem paga; dependência de conexão externa e dados de terceiros	**Soberania e Privacidade:** Execução 100% local (Ollama) com banco vetorial persistente
Tutoria Adaptativa (Modran, 2025)	RAG + MCP e ACP para modulação pedagógica	Foco em perfil de aprendizagem, sem isolamento formal de leitura nem auditoria estrita	**Governança via MCP:** Ferramentas isoladas operando em modo estrito de leitura (*read-only*)
Gestão OpenStack (Oliveira, 2025)	Multiagente MCP para automação de infra	Agentes com permissão de escrita/modificação ativa em serviços do sistema operacional	**Auditabilidade Documental:** Foco exclusivo em ancoramento factual com fontes explícitas

Viabilidade Real do *Self-Hosted*: o sistema roda em um servidor local (*homelab*) com GPU, usando um modelo compacto de 4B parâmetros, sem custo por token nem envio de dados a terceiros. Em testes, o RAG Clássico começou a responder em **1,5 a 2,2 s**, e um semáforo de VRAM mantém o serviço estável com requisições simultâneas. O mesmo ambiente comparou o **RAG Clássico** com o **Agente MCP**.

Slide 4 — Metodologia (1/3): Arquitetura e Tecnologias

Pilha Tecnológica 100% Local e Soberana

- **Estrutura em Monorepo (npm workspaces):**
  - `packages/web`: React 19 + TypeScript + Vite (interface web e streaming SSE);
  - `packages/api`: Backend Node.js/Express + controle assíncrono;
  - `packages/mcp-server`: Servidor de ferramentas isolado via protocolo MCP.
- **Modelos de Inteligência Artificial (Ollama local):**
  - **Qwen 3.5 4B:** Reescrita de consulta, raciocínio agêntico e geração;
  - **BGE-M3:** Vetorização multilíngue densa (1024 dimensões).
- **Banco Vetorial:** PostgreSQL 16 + *pgvector* (índices HNSW).

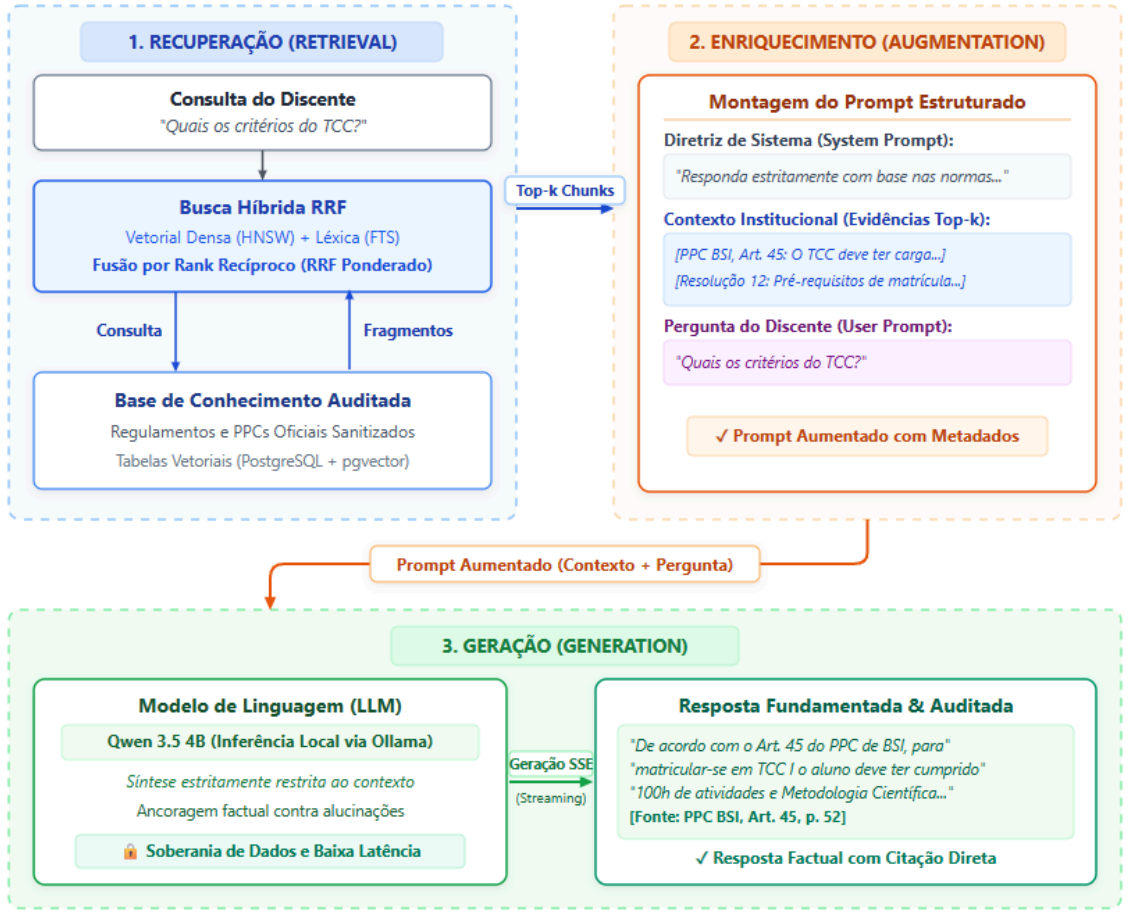


Figura 1: Arquitetura geral, fluxo de dados do pipeline RAG e ingestão.

Slide 5 — Metodologia (2/3): Ingestão e Sanitização Adaptativa

1. Extração Multiformato

Leitura resiliente de documentos heterogêneos:

- **PDF Estruturado:** *LiteParse* preservando hierarquia de seções e títulos;
- **PDF Escaneado:** OCR local via *tesseract.js*;
- Planilhas curriculares e matrizes em Markdown.

2. Sanitização em 8 Etapas

1. Filtragem de ruídos de OCR e caracteres nulos;
2. Junção de hifenizações em quebra de linha;
3. Poda de cabeçalhos e rodapés repetitivos;
4. Eliminação de formulários em branco;
5. Linearização textual de tabelas curriculares;
6. Remoção de numeração isolada de páginas;
7. Padronização formal antes de *Art.* e *Capítulo*;
8. Normalização de espaços e pontuação.

3. Domain-Driven Chunking

Segmentação orientada à semântica normativa:

- **Syllabus Strategy:** Disciplina completa mantida no mesmo chunk (código, ementa, créditos e bibliografia);
- **Normative Strategy:** Preserva artigos, parágrafos e incisos sem fracionamento cego;
- Prefixo contextual injetado em cada vetor.

Benefício Chave: Elimina a quebra de artigos regulamentares no meio de frases, problema comum em segmentações cegas baseadas apenas em contagem de caracteres.

Slide 6 — Metodologia (3/3): RAG Clássico vs. Agente MCP e GPU

RAG Clássico (Linear)

- **Fluxo Determinístico:** Reescrita de consulta $\to$ Busca Híbrida RRF $\to$ Síntese direta com streaming SSE;
- **Busca Híbrida Calibrada ($\alpha = 0,5$):** Equilíbrio exato entre semântica vetorial (BGE-M3) e termos léxicos (FTS);
- **Menor Latência:** Sem ciclos intermediários de decisão.

RAG Agêntico via MCP (Autônomo)

- **Comunicação via stdio:** Processo desacoplado com contrato de schema JSON rigoroso;
- **Ferramenta Dedicada:** `search_ifmg_knowledge` operando exclusivamente em modo de leitura (*read-only*);
- **Rastreabilidade de Fontes:** Anexa metadados auditáveis com o nome do regulamento e trecho citado.

Engenharia de Concorrência: Semáforo Assíncrono de VRAM

Para prevenir travamentos por estouro de memória de vídeo (*Out-Of-Memory* — OOM) no servidor homelab, implementou-se um **semáforo de concorrência em memória** (`OLLAMA_MAX_CONCURRENT = 2`). Requisições excedentes são enfileiradas com timeout gracioso, dispensando dependências pesadas de corretores externos (Redis/RabbitMQ).

Slide 7 — Resultados Preliminares (1/3): Métricas de Latência

Ambiente Computacional Homelab

- **Servidor Local** (Ubuntu 24.04, *self-hosted*):
  - CPU: AMD Ryzen 5 7500F (6 núcleos / 12 *threads*);
  - GPU: NVIDIA RTX 5060 Ti, 16 GB de VRAM (CUDA);
  - Memória RAM: 32 GB;
  - Armazenamento: SSD de 512 GB (PCIe Gen3).
- **Modelos Locais:**
  - LLM: *Qwen 3.5 4B Instruct* (4 bilhões de parâmetros, contexto de 2048 *tokens*);
  - Embeddings: *BGE-M3* (1024 dimensões).
- **Banco de Dados:** PostgreSQL 16 + pgvector (HNSW).

> **Time To First Token (TTFT):** Início de transmissão entre **1,5 s e 2,2 s** no RAG Clássico via SSE, garantindo percepção imediata de atividade.

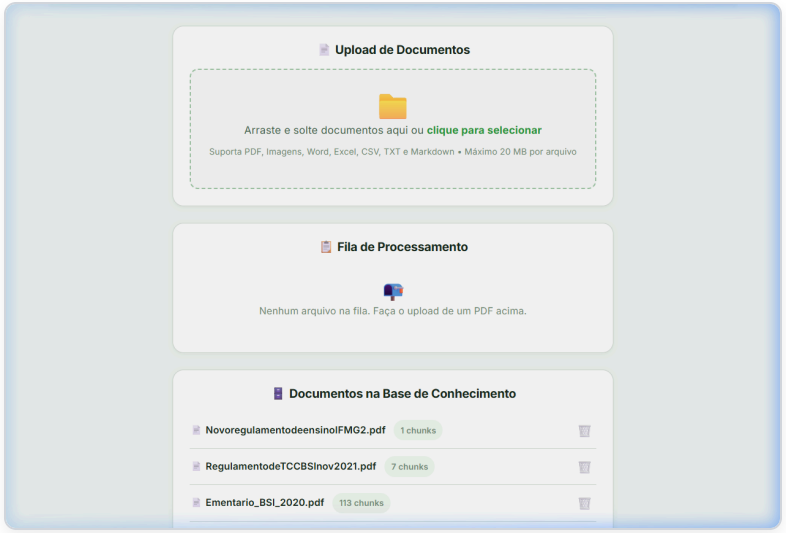
Tempos Médios por Etapa do Pipeline

Etapa do Pipeline	Componente / Modelo	Latência Média
Reescrita de Consulta	Qwen 3.5 4B	800 a 1500 ms
Vetorização (Embedding)	BGE-M3 (1024d)	100 a 300 ms
Busca Híbrida RRF	PostgreSQL HNSW + FTS	**50 a 120 ms**
Latência Total RAG Clássico	Geração Completa SSE	**57,3 s (média)**
Latência Total Agente MCP	Turnos de Tool Calling	**84,6 s (média)**

Sobretaxa de +47,7% (+27,3 s) no agente devido a múltiplos turnos inferenciais.

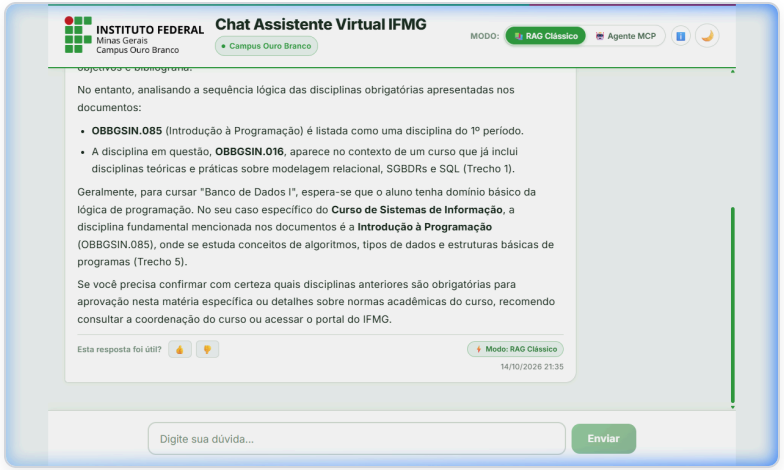
Slide 8 — Resultados Preliminares (2/3): Demonstração em Produção

1. Ingestão de Documentos



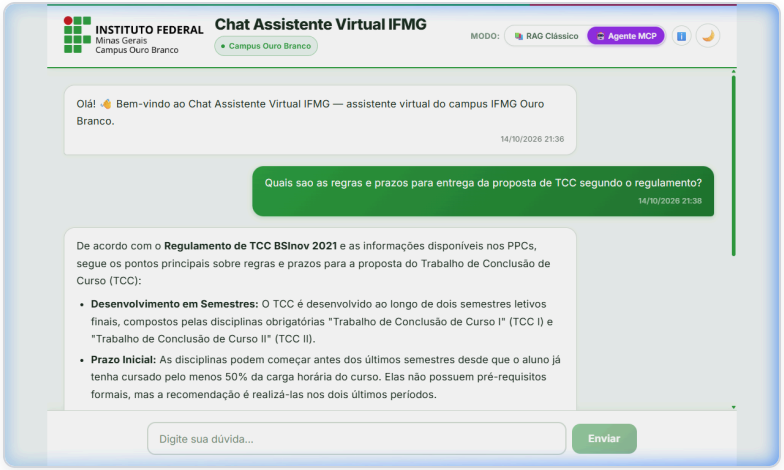
Indexação vetorial em produção: **468+ chunks** (PPC BSI, Ementário, Metalúrgica e TCC).

2. Modo RAG Clássico



Consulta de pré-requisitos com resposta factual direta e botões de feedback discente.

3. Modo Agente MCP



Consulta sobre TCC com citação explícita das fontes oficiais auditadas via ferramenta.

Sistema em execução online pública para validação: **https://chat.danielgsilva.com.br/**

Slide 9 — Resultados Preliminares (3/3): Avaliação com Usuários

Amostragem em Campo

41 Interações

Coleta real com grupo piloto discente:

- **RAG Clássico:** 30 consultas (**73,2%**);
- **Agente MCP:** 11 consultas (**26,8%**).

Preferência espontânea pela maior rapidez do RAG linear.

Normas Mais Acionadas

- **PPCBSI_2022.pdf:** 34 ativações diretas na base vetorial;
- **Ementario_BSI_2020.pdf:** 29 ativações agregadas;
- **PPC_Metalurgica:** 28 ativações;
- **Regulamento TCC:** 4 ativações.

Temáticas Consultadas

- **Matriz e Cursos:** 9 consultas;
- **Ementas de Disciplinas:** 8 consultas;
- **Normas de TCC e Estágio:** 2 consultas;
- **Faltas e Avaliações:** 2 consultas;
- **Consultas Gerais / Outras:** 15 consultas.

Análise Crítica dos Feedbacks: Respostas avaliadas positivamente (👍) relacionam-se a ementas e carga horária. Avaliações negativas (👎) decorreram de perguntas fora do escopo normativo (horários de aula, telefone da secretaria), em que o sistema corretamente recusou inventar informações.

Slide 10 — Discussões: Trade-Offs e Lições Aprendidas

Trade-Off: Latência vs. Governança

- **RAG Clássico (Determinístico):** Entrega menor tempo total e maior estabilidade em hardware modesto, sendo a escolha ideal para o cotidiano do aluno;
- **Agente MCP (Modular):** Oferece governança formal, auditabilidade e rastreabilidade estrita de fontes, mas com sobretaxa temporal de +47,7%;
- A modularidade do MCP compensa quando se planeja expansão para múltiplos agentes e bancos regulatórios complexos.

Desafios de Modelos Compactos (4B)

- **Sensibilidade de Janela:** Em modelos de 4 bilhões de parâmetros, a janela de contexto de 2048 tokens satura com rapidez em turnos sucessivos;
- **Sintaxe de Function Calling:** Modelos 4B podem hesitar na chamada de ferramentas em perguntas ambíguas;
- **Alinhamento de Expectativas:** Necessidade de orientar o aluno discente sobre o escopo regulamentar estático suportado pela aplicação.

Síntese da Discussão: Em infraestrutura local compacta, o RAG Clássico é superior para consultas rápidas, enquanto o MCP estabelece as bases de governança que se beneficiarão do avanço para modelos 8B e superiores.

Slide 11 — Cronograma de Conclusão: Próximas Etapas (6 Semanas)

Semanas 1 e 2

Experimentos & Correções

- Oficina prática com alunos na **SNCT 2026** (coleta de novas avaliações);
- Refino de prompts para mitigar falhas de JSON em modelos 4B;
- Ajuste fino no semáforo de GPU.

Semanas 3 e 4

Análise & Redação

- Tabulação quantitativa e qualitativa dos novos feedbacks;
- Escrita detalhada da seção de **Resultados e Discussão** no artigo científico;
- Consolidação dos dados de latência e acurácia.

Semana 5

Conclusão & Limitações

- Redação da Conclusão e Limitações metodológicas;
- Detalhamento de **Trabalhos Futuros** (avaliação via RAGAS e modelos 8B/14B);
- Revisão do Resumo e Abstract do artigo.

Semana 6

Revisão & Defesa

- Revisão textual rigorosa com o orientador;
- Ajustes finais de formatação do artigo segundo o modelo SBC;
- Preparação da apresentação final para a banca examinadora.

Situação Atual: O protótipo está 100% funcional em produção. As próximas 6 semanas consolidarão os dados experimentais, correções e a redação científica definitiva do artigo.

Slide 12 — Referências Bibliográficas

- **Anthropic.** *Model Context Protocol (MCP) Specification*, 2024. Disponível em: <https://modelcontextprotocol.io>.
- **Barbosa, L. S.** *Um Chatbot Especializado para o Contexto da Universidade Federal de Ouro Preto*. Monografia (Bacharelado em Ciência da Computação) — UFOP, Ouro Preto, 2023.
- **Chen, J. et al.** *BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. arXiv preprint arXiv:2402.03216, 2024.
- **Cormack, G. V.; Clarke, C. L. A.; Büttcher, S.** Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In: *Proceedings of the 32nd International ACM SIGIR Conference*, p. 758–759, 2009.
- **IFMG Campus Ouro Branco.** *Projeto Pedagógico do Curso de Bacharelado em Sistemas de Informação (PPCBSI)*, 2022.
- **Lewis, P. et al.** Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In: *Advances in Neural Information Processing Systems (NeurIPS)*, v. 33, p. 9459–9474, 2020.
- **Modran, H. A.** Leveraging RAG with ACP & MCP for Adaptive Intelligent Tutoring. *Applied Sciences*, MDPI, v. 15, n. 21, p. 11443, 2025.
- **Monteiro, G. S.** *Helena: Um chatbot para auxílio dos discentes do DECOM em trâmites universitários*. Monografia (Bacharelado em Ciência da Computação) — UFOP, Ouro Preto, 2021.
- **Oliveira, I. K. S.** *Uma Arquitetura Multiagente para Orquestração Automática em Infraestruturas OpenStack*. TCC (Bacharelado em Engenharia de Computação) — IFPB, Campina Grande, 2025.

Muito Obrigado!

Chat Assistente Virtual Acadêmico — IFMG Campus Ouro Branco

Discente: Daniel G. D. Silva (daniel24maio@gmail.com)
Orientador: Prof. Me. Ederson N. F. G. Júnior (ederson.junior@ifmg.edu.br)
Aplicação em Produção: https://chat.danielgsilva.com.br/

Estamos à disposição da banca examinadora para perguntas e apontamentos.