

Desenvolvimento de um Assistente Virtual Acadêmico Local Baseado em Agentic RAG e Model Context Protocol sob Infraestrutura de Hardware Restrito

Daniel G. D. Silva¹, Ederson N. F. G. Júnior¹

¹Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais (IFMG)
Campus Ouro Branco – MG – Brasil

daniel24maio@gmail.com, ederson.junior@ifmg.edu.br

Abstract. *This research project outlines the development and comparative evaluation of an institutional virtual assistant configured to clarify academic regulations using localized Large Language Models (LLMs). The architecture synthesizes standard Retrieval-Augmented Generation (RAG) with the emerging Model Context Protocol (MCP) using open-source infrastructure hosted locally.*

Resumo. *Este projeto de pesquisa descreve o desenvolvimento e a avaliação comparativa de um assistente virtual institucional configurado para sanar dúvidas sobre regulamentos acadêmicos utilizando Modelos de Linguagem de Grande Escala (LLMs) locais. A arquitetura sintetiza a abordagem de Geração Aumentada por Recuperação (RAG) híbrida com o protocolo emergente Model Context Protocol (MCP) por meio de infraestrutura open-source hospedada localmente.*

1. Introdução e Contextualização

A gestão da informação em instituições de ensino superior lida com um grande volume de diretrizes, regulamentos acadêmicos e projetos pedagógicos de curso (PPC). No Instituto Federal de Minas Gerais (IFMG) - Campus Ouro Branco, essas informações encontram-se dispersas em arquivos não estruturados, gerando falhas de comunicação, frustração no corpo discente e uma sobrecarga crônica de atendimentos repetitivos na secretaria administrativa e na coordenação do curso de Sistemas de Informação.

O avanço recente dos Modelos de Linguagem de Grande Escala (LLMs) abriu caminhos para automação desse atendimento via interfaces conversacionais. No entanto, LLMs puros operam de forma probabilística e sofrem com alucinações, o que inviabiliza seu uso em cenários regulatórios rígidos. Para resolver essa restrição, a arquitetura de Geração Aumentada por Recuperação (RAG) consolidou-se ao injetar contextos externos. Este projeto de pesquisa propõe investigar a fusão do RAG com o novo padrão de engenharia corporativa *Model Context Protocol* (MCP) [Sabbag Filho 2025], validando um ecossistema de software local e soberano rodando em *homelab*.

2. Problema de Pesquisa

Diante das restrições computacionais de *hardware* local e da necessidade de acurácia factual absoluta em ambientes acadêmicos, formula-se o seguinte problema: De que maneira a integração do Model Context Protocol (MCP) a uma arquitetura Agentic RAG local consegue mitigar as alucinações factuais no esclarecimento de dúvidas regulamentares acadêmicas, mantendo a viabilidade operacional e de latência em servidores de pequeno porte?

3. Hipóteses

- **H₁:** A padronização de contratos de interface via primitivas MCP (*Tools* e *Resources*) estabelece uma barreira de governança rígida que restringe o escopo de alucinação do modelo local em comparação com implementações RAG lineares tradicionais.
- **H₂:** Modelos locais de pequeno porte (como o Qwen 4B) manifestam gargalos de *Tool Calling* ao lidar com janelas de contexto saturadas por documentações jurídicas complexas, tornando o RAG Clássico baseado em *Query Rewriting* e *Reciprocal Rank Fusion* (RRF) mais estável sob restrições físicas de memória.

4. Objetivos

4.1. Objetivo Geral

Desenvolver, implantar e analisar comparativamente um assistente virtual inteligente baseado em RAG híbrido e no protocolo MCP para sanar dúvidas sobre os regulamentos acadêmicos do curso de Sistemas de Informação do IFMG - Campus Ouro Branco, validando sua eficácia técnica e operacional sob infraestruturas locais de computação.

4.2. Objetivos Específicos

- Estruturar um pipeline automatizado de ingestão, limpeza e fragmentação semântica em 8 etapas para converter os documentos oficiais em vetores densos.
- Implementar um banco de dados relacional PostgreSQL equipado com a extensão *pgvector* utilizando indexação HNSW acoplada a um motor de busca textual por texto completo.
- Desenvolver um servidor MCP autônomo que publique as capacidades de busca institucional sob esquemas declarativos rígidos de *Function Calling*.
- Construir um semáforo de concorrência ativa baseado em memória e controle de conexões para blindar a GPU local contra falhas de estouro de memória física.

5. Justificativa

A relevância prática deste projeto reside na descentralização e democratização do acesso às normas institucionais, concedendo autonomia ao estudante e desafogando os canais físicos de atendimento da secretaria do IFMG. Sob a ótica científica e de Engenharia de Software, a pesquisa justifica-se ao explorar as fronteiras do *Model Context Protocol* aplicada a LLMs locais e compactos, provando que instituições públicas podem conceber sistemas de inteligência artificial inteiramente soberanos, seguros e de baixo custo, sem submeter dados públicos a APIs proprietárias e nuvens corporativas estrangeiras.

6. Procedimentos Metodológicos e Cronograma de Avaliação

A pesquisa caracteriza-se como um estudo de natureza aplicada, com abordagem qualitativa e quantitativa, utilizando procedimentos experimentais de engenharia de software. Os testes operacionais e a validação do sistema serão conduzidos em três fases progressivas interdependentes, cujas datas específicas de calendário serão acordadas conforme o andamento das janelas letivas institucionais:

- **Fase 1 (Validação Alpha):** Envolverá um grupo restrito de 10 usuários voluntários, composto majoritariamente por indivíduos vinculados diretamente ao ecossistema do curso de Sistemas de Informação, englobando discentes, docentes e representantes da secretaria administrativa do campus. O foco desta fase é validar a estabilidade primária das rotas da API e verificar a coerência conceitual inicial das respostas geradas pelo pipeline.
- **Fase 2 (Validação Beta Expandida):** Amostragem estendida para um grupo composto por 15 a 20 usuários. O objetivo principal é avaliar a performance do semáforo de concorrência ativa sob requisições paralelas simultâneas e coletar logs de latência em um cenário de uso real descentralizado.
- **Fase 3 (Teste de Estresse e Robustez):** Realização de testes de carga com um grupo de usuários instruídos a interagir de forma agressiva com o sistema, submetendo perguntas ambíguas, com erros ortográficos intencionais ou desvios de assunto. O escopo é estressar os limites da janela de contexto de 2048 *tokens*.

Paralelamente às três fases, serão conduzidas rotinas automáticas de coleta de informações operacionais para analisar o que foi previsto em nível de design de software e não obteve sucesso prático, avaliando se eventuais falhas factuais decorreram de limitações semânticas de contexto do modelo ou de inadequações no tamanho e sobreposição dos fragmentos gerados pelo pipeline de *chunking* adaptativo. O sistema não coletará, armazenará ou processará nenhuma informação que permita identificar direta ou indiretamente o usuário, eliminando a necessidade de cadastro para assegurar o anonimato absoluto.

7. Orçamento e Infraestrutura Local

Como estratégia fundamental de Engenharia de Software e viabilidade econômica para instituições públicas, este projeto foi concebido para mitigar a dependência de plataformas de nuvem proprietárias e contornar os custos recorrentes de mensalidades ou tarifação flutuante por volumetria de consumo de *tokens* cobrados por grandes provedores do mercado de inteligência artificial, tais como OpenAI, Google Cloud Vertex AI, Anthropic, Microsoft Azure AI, Amazon Bedrock e Cohere.

Para viabilizar a autonomia computacional local e a soberania dos dados do campus, a infraestrutura física de execução foi totalmente financiada com recursos próprios do pesquisador, consistindo em uma estação de trabalho composta por um processador AMD Ryzen 5 7500F, 32 GB de memória RAM DDR5, unidade de estado sólido SSD NVMe Gen 3 de 500 GB, e uma unidade de processamento gráfico dedicada NVIDIA GeForce RTX 5060 Ti equipada com 16 GB de VRAM. A especificação desta GPU com 16 GB de memória de vídeo constitui o elemento mandatório para o sucesso da pesquisa, permitindo carregar simultaneamente os modelos locais de representação vetorial (*bge-m3*) e inferência (*qwen3.5:4b*). Desse modo, o custo financeiro direto de insumos institucionais para o projeto caracteriza-se como zero.

Referências

Sabbag Filho, N. (2025). Model context protocol (mcp): Conectando contexto, agentes e arquitetura de software moderna. *Leaders.Tec.Br*, 2(37):1–12.